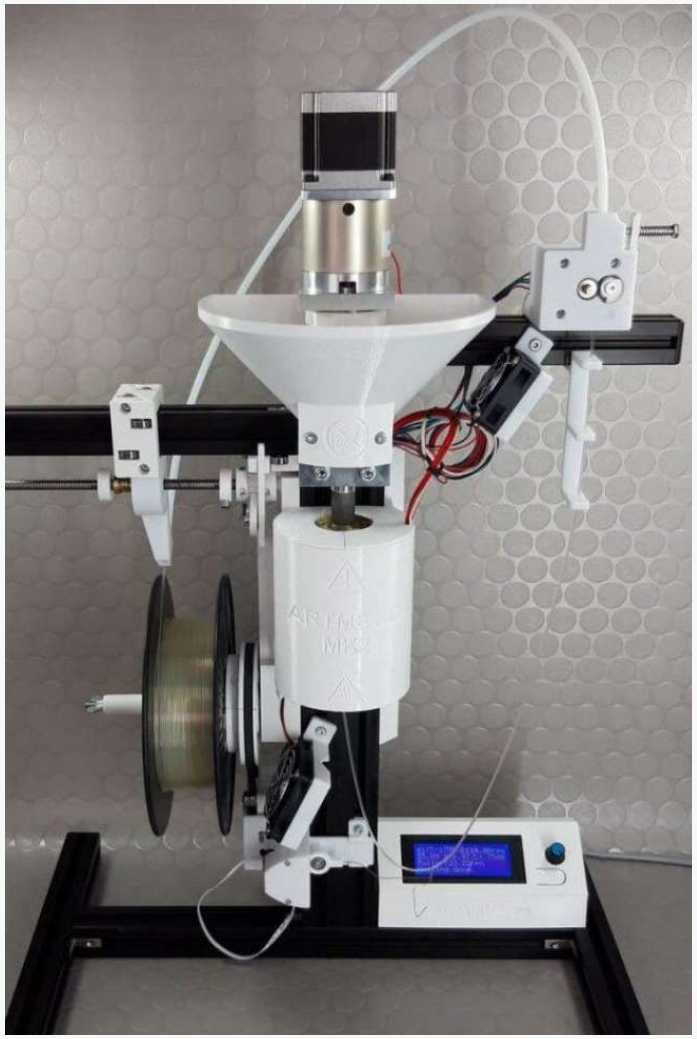
Business Case & Mehrwert



Probleme in der Produktion

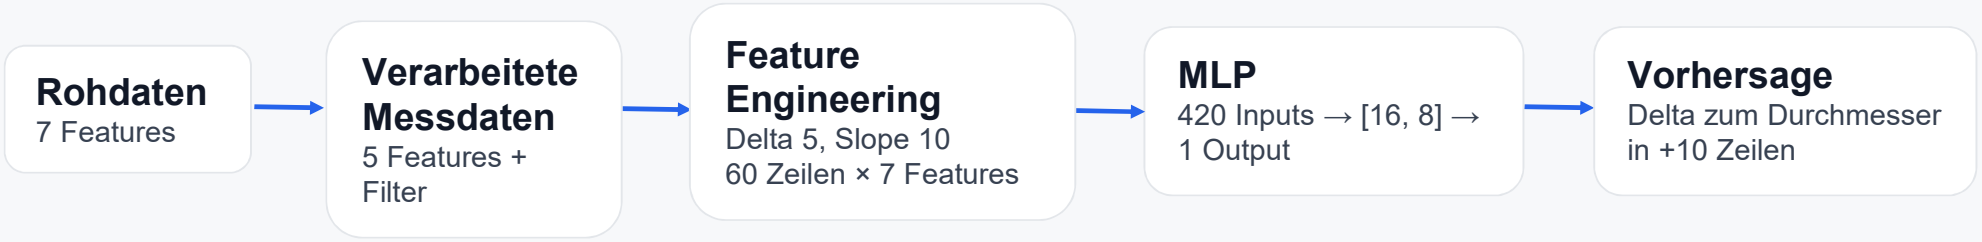
- Prozessinstabilität
- Lange, variable Totzeit
- Durchmesser nicht direkt einstellbar

Business Case

- Ziel: Durchmesser soll regelbar sein
- Dazu: Vorhersage von Filamentdurchmesser

KI-Architektur & Modellauswahl

Verwendete KI: dynamisches Multi-Layer-Perceptron



Warum dieses Modell?

- Dynamisches MLP, da Totzeit und Trägheit des Systems
- Feature Engineering und Delta-Ziel erhöht Genauigkeit: gelernt wird die relevante Trendänderung

Datenbezug

- Jede Sequenz enthält die letzten 60 Messpunkte.
- Features werden mit StandardScaler normalisiert.
- Das vorhergesagte Delta wird zum letzten gemessenen Durchmesser addiert.

Modellkonfiguration & Hyperparameter

Einstellparameter und Optimierung des MLP-Modells

Finale Konfiguration

- Input: 60 × 7 Features = 420 Werte
- Prediction Horizon: 10 Zeilen ≈ 10 Sekunden
- Architektur: small_16_8 mit Hidden Layers [16, 8]
- Aktivierungen: ReLU hidden, linearer Output
- Dropout: 0,25 | L2-Regularisierung: 0,001
- Optimizer: Adam | Learning Rate: 0,001
- Loss: Huber -> hilft, Ausreißer besser auszugleichen
- Batch Size: 32 | max. 100 Epochen, tatsächlich 33

Getestete Einstelloptionen

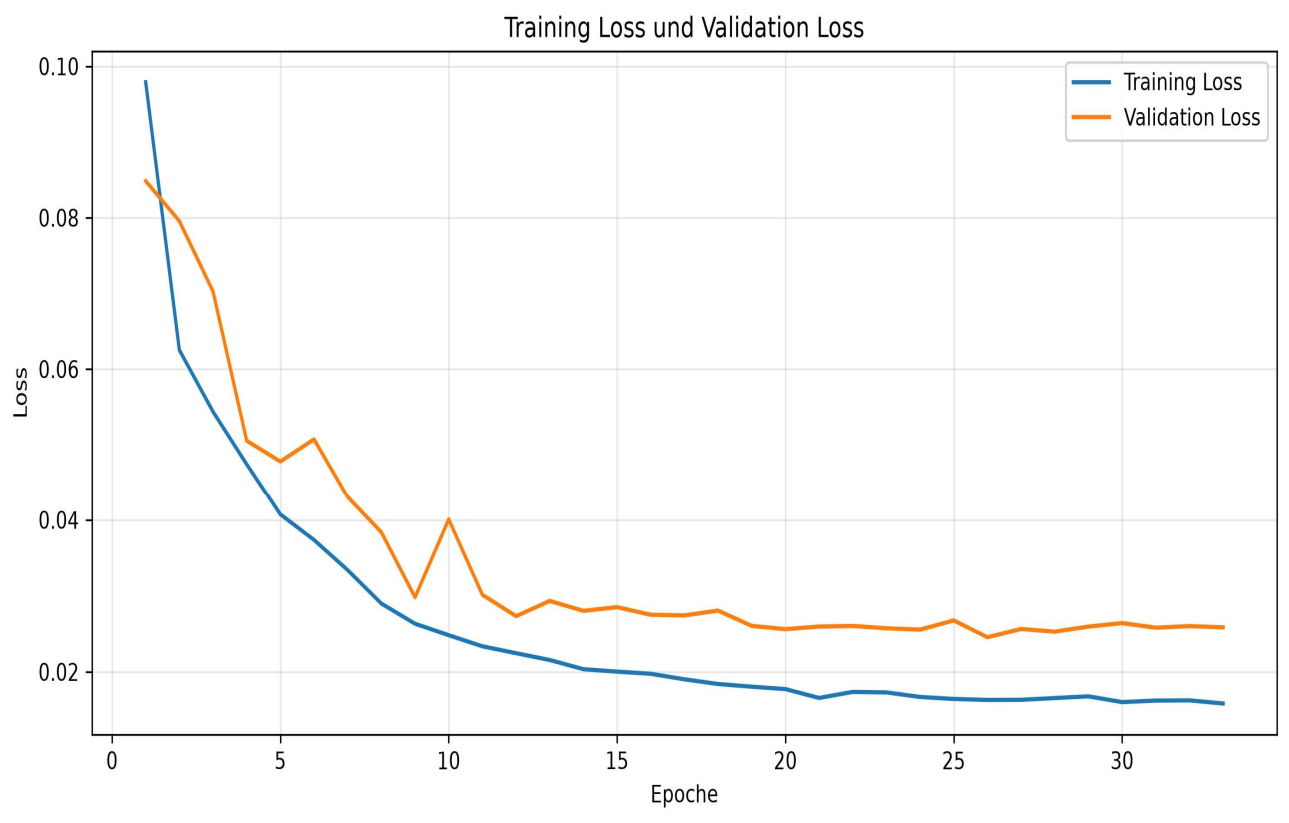
- Optuna-Suche
- Architekturen: <= 5 Hidden Layer mit bis zu 128 Neuronen
- Dynamische wie statische MLPs
- Dropout, L2-Rate, Learning Rate, Batch Size, Sequenzlänge, Aktivierungsfunktion und Early-Stopping

Trainingskontrolle

- Early Stopping auf val_loss, patience=7, min_delta=5e-05
- Restore Best Weights aktiviert
- Learning-Rate-Reduktion: Faktor 0,5, patience=3, min_lr=1e-06

Training & Ergebnisse

Loss Function über den Trainingsverlauf und quantitative Modellgüte



Trainingsergebnis

- Epochen: max. 100, Early Stop nach 33
- Batch Size: 32
- Final Training Loss: 0,0144
- Final Validation Loss: 0,0245
- Test Loss: 0,0428
- **Test MAE: 0,0120 mm**
- Baseline MAE: 0,0143 mm
- **≈ 16 % geringerer Fehler als die Baseline**

Interpretation: Die Validation Loss folgt der Training Loss mit moderatem Abstand; Early Stopping begrenzt Overfitting. Die Testabweichung liegt im Bereich von ca. 0,012 mm und ist damit besser als die Baseline.

Zielerreichung & Digitale Umsetzung

Praxisnachweis: lokale Anwendung mit CSV-Replay und Live-GUI

